

Introduction aux modèles statiques en données de panel

Avec application au lien climat–rendement agricole

Cours synthétique pour débutant

13 décembre 2025

Table des matières

1	Introduction générale	2
2	Données de panel : notation et structure	2
3	Modèles statiques en données de panel	3
3.1	Modèle pooling (régression classique)	3
3.2	Modèle à effets fixes (Fixed Effects, FE)	3
3.3	Modèle à effets aléatoires (Random Effects, RE)	3
3.4	Illustration graphique : effets fixes vs effets aléatoires	4
4	Tests de spécification de Hsiao (2003)	5
4.1	Logique générale et arbre de décision	5
4.2	Étape 1 : homogénéité complète (test F_1)	5
4.3	Étape 2 : pentes communes ou non ? (test F_2)	5
4.4	Étape 3 : intercepts communs ou effets fixes ? (test F_3)	6
4.5	Illustration du processus	6
5	Application : climat et PIB agricole	6
5.1	Spécification économétrique	6
5.2	Interprétation des coefficients dans ce contexte	7
5.3	Implémentation pratique en R (avec <code>plm</code>)	7

1 Introduction générale

En économétrie, on distingue plusieurs grands types de données :

- **Données transversales** : un seul moment dans le temps, plusieurs unités (ménages, pays, entreprises, ...).
- **Séries temporelles** : une seule unité observée sur plusieurs périodes (PIB du Sénégal de 1980 à 2023, par exemple).
- **Données de panel** (ou longitudinales) : plusieurs unités *et* plusieurs périodes pour chaque unité.

Les **données de panel** combinent donc information *transversale* et *temporelle*. Elles permettent de suivre un même individu (ou pays) au cours du temps, et sont très utiles pour :

- contrôler les caractéristiques inobservées mais fixes dans le temps,
- mieux identifier des relations causales,
- modéliser des dynamiques (lag de la variable dépendante, etc., mais ici on reste au modèle statique).

Dans ce cours, on se concentre sur les **modèles statiques de panel** et les **tests de spécification de Hsiao (2003)**, en les illustrant sur un exemple lié à ton projet : l'impact du climat (température, précipitations, jours chauds) sur le rendement ou le PIB agricole.

2 Données de panel : notation et structure

On note généralement :

- $i = 1, \dots, N$: les unités (pays, ménages, entreprises, etc.) ;
- $t = 1, \dots, T$: les périodes (années, trimestres, etc.) ;
- Y_{it} : la variable dépendante (ici, par exemple, log du PIB agricole du pays i à l'année t) ;
- X_{it} : un vecteur de K variables explicatives pour l'unité i à la période t (ici : degrés-jours, précipitations, jours très chauds, etc.).

Exemple de structure de panel climat–agriculture

Supposons que l'on dispose des données suivantes :

- Pays d'Afrique : Sénégal, Mali, Burkina Faso, Niger, Tchad, Madagascar, Mauritanie, Soudan ;
- Période : 2010–2023 ;
- Variables :
 - Y_{it} : log du PIB agricole (ou du rendement moyen) du pays i à l'année t ;
 - degdays_{it} : degrés-jours de croissance (chaleur utile) ;
 - rain_{it} : précipitations cumulées en saison de croissance ;
 - hotdays_{it} : nombre de jours très chauds (au-dessus d'un seuil).

Un extrait fictif de la base pourrait ressembler au tableau 1.

TABLE 1 – Exemple simplifié de structure de panel climat–PIB agricole

Pays (i)	Année (t)	degdays_{it}	rain_{it}	hotdays_{it}	$\log(\text{PIB agri}_{it})$
Sénégal	2010	1250	650	32	10.8
Sénégal	2011	1300	620	34	10.9
...
Mali	2010	1400	590	36	10.5
Mali	2011	1380	610	35	10.6
...

3 Modèles statiques en données de panel

L'idée de base est de relier Y_{it} aux variables explicatives X_{it} par un modèle linéaire. Dans ce cours, on utilise la forme suivante :

$$Y_{it} = \alpha_i + \gamma_t + \beta' X_{it} + \varepsilon_{it}, \quad (1)$$

où :

- α_i : effet spécifique à l'unité (pays) i , constant dans le temps ;
- γ_t : effet spécifique à l'année t (choc commun à tous les pays) ;
- β : vecteur de coefficients (effet moyen de X_{it} sur Y_{it}) ;
- ε_{it} : terme d'erreur idiosyncratique.

Selon la façon dont on traite α_i (et éventuellement γ_t), on obtient différents modèles : **pooling, effets fixes, effets aléatoires**.

3.1 Modèle pooling (régression classique)

Le modèle le plus simple ignore complètement la structure de panel et suppose :

$$Y_{it} = \alpha + \beta' X_{it} + \varepsilon_{it}, \quad (2)$$

avec un *même* intercept α et les mêmes coefficients β pour tous les pays et toutes les périodes.

C'est une simple régression OLS sur toutes les observations empilées, comme si l'on avait une grande base de données transversale.

Limite principale : toutes les différences permanentes entre pays (qualité des sols, institutions, etc.) sont noyées dans l'erreur. Si ces caractéristiques sont corrélées avec les variables explicatives, on a un **biais d'omission**.

3.2 Modèle à effets fixes (Fixed Effects, FE)

Dans le modèle à **effets fixes individuels**, on autorise un intercept spécifique à chaque pays :

$$Y_{it} = \alpha_i + \beta' X_{it} + \varepsilon_{it}, \quad (3)$$

où α_i capte toutes les caractéristiques inobservées mais *constantes dans le temps* du pays i : qualité moyenne des terres, institutions, niveau structurel de productivité agricole, etc.

On peut également ajouter des effets fixes temporels :

$$Y_{it} = \alpha_i + \gamma_t + \beta' X_{it} + \varepsilon_{it}, \quad (4)$$

ce qui permet de contrôler les chocs communs à tous les pays (prix mondiaux des céréales, tendance globale du climat, etc.).

Idée clé : le modèle FE exploite les *variations dans le temps à l'intérieur d'un même pays*. Les coefficients β s'interprètent comme l'effet d'un changement de climat (par exemple une augmentation des degrés-jours) sur Y_{it} , *une fois que l'on tient compte du pays considéré*.

3.3 Modèle à effets aléatoires (Random Effects, RE)

Dans le modèle à **effets aléatoires**, on suppose :

$$Y_{it} = \alpha + u_i + \beta' X_{it} + \varepsilon_{it}, \quad (5)$$

où u_i est un effet spécifique au pays i mais traité comme une variable aléatoire, avec :

$$\mathbb{E}[u_i] = 0, \quad \text{Var}(u_i) = \sigma_u^2,$$

et, surtout, on suppose :

$$\text{Cov}(u_i, X_{it}) = 0 \quad \forall i, t.$$

Autrement dit, les caractéristiques inobservées propres au pays i ne sont pas corrélées aux variables explicatives X_{it} . C'est une hypothèse forte et souvent discutée en pratique.

Conséquence :

- Si l'hypothèse $\text{Cov}(u_i, X_{it}) = 0$ est vraie, le modèle RE est plus efficace (plus précis) que FE.
- Si elle est fausse, les estimations RE sont biaisées, et il vaut mieux utiliser FE.

3.4 Illustration graphique : effets fixes vs effets aléatoires

La figure 1 illustre schématiquement la différence entre un monde « effets fixes » et un monde où les pentes/intercepts varient aléatoirement.




FIGURE 1 – Illustration : données compatibles avec un modèle à effets fixes (haut) ou à coefficients aléatoires (bas).

Dans la partie supérieure, les droites des différents groupes sont « parallèles » : les pentes sont communes, seuls les intercepts changent. C'est l'intuition du modèle à effets fixes individuels avec pente commune.

4 Tests de spécification de Hsiao (2003)

La question pratique est : *quel modèle choisir ? Pooling ? Effets fixes ? Effets aléatoires ? Avec pentes communes ou spécifiques ?*

Plusieurs critères peuvent guider le choix :

- arguments théoriques et économiques,
- inspection graphique,
- tests économétriques : ici, les tests de **Hsiao (2003)**.

4.1 Logique générale et arbre de décision

Hsiao (2003) propose une séquence de tests F pour comparer plusieurs spécifications imbriquées. On considère, pour simplifier, le cas d'une seule variable explicative X_{it} et trois grandes familles de modèles :

- (1) Pooled : $Y_{it} = \alpha + \beta X_{it} + \varepsilon_{it}$,
- (2) Effets fixes individuels : $Y_{it} = \alpha_i + \beta X_{it} + \varepsilon_{it}$,
- (3) Pentes et intercepts spécifiques : $Y_{it} = \alpha_i + \beta_i X_{it} + \varepsilon_{it}$.

Les tests reposent sur la comparaison des **sommes des carrés des résidus** (SCR) entre modèles contraints et non contraints.

4.2 Étape 1 : homogénéité complète (test F_1)

On compare :

- **Modèle non constraint (Mnc)** : $Y_{it} = \alpha_i + \beta_i X_{it} + \varepsilon_{it}$;
- **Modèle constraint (Mc)** : $Y_{it} = \alpha + \beta X_{it} + \varepsilon_{it}$.

Hypothèses :

$$H_0^1 : \alpha_i = \alpha \text{ et } \beta_i = \beta \quad \forall i \quad (\text{homogénéité complète}),$$

$$H_1^1 : \exists (i, j) \text{ tels que } \alpha_i \neq \alpha_j \text{ ou } \beta_i \neq \beta_j.$$

Notons :

- SCR_1 : somme des carrés des résidus du modèle non contraint (Mnc) ;
- $SCR_{1,c}$: somme des carrés des résidus du modèle constraint (Mc).

La statistique de test est :

$$F_1 = \frac{(SCR_{1,c} - SCR_1)/[(n-1)(K+1)]}{SCR_1/[nT - n(K+1)]}, \quad (6)$$

où n est le nombre d'unités (pays), T le nombre de périodes et K le nombre de variables explicatives.

On rejette H_0^1 si F_1 est trop grand par rapport à la loi F avec $[(n-1)(K+1)]$ et $[nT - n(K+1)]$ degrés de liberté.

4.3 Étape 2 : pentes communes ou non ? (test F_2)

Si H_0^1 est rejetée, on sait que le modèle pooled est trop restrictif. On se demande alors si au moins les **pentes** peuvent être communes.

On compare :

- **Modèle non constraint (Mnc)** : $Y_{it} = \alpha_i + \beta_i X_{it} + \varepsilon_{it}$;
- **Modèle constraint (Mc)** : $Y_{it} = \alpha_i + \beta X_{it} + \varepsilon_{it}$ (effets fixes individuels, pente commune).

Hypothèses :

$$H_0^2 : \beta_i = \beta \quad \forall i \quad (\text{pentes communes}),$$

$$H_1^2 : \exists (i, j) \text{ tels que } \beta_i \neq \beta_j.$$

Notons :

- SCR_1 : SCR du modèle non contraint (le même que pour F_1) ;
- $SCR_{1,c'}$: SCR du modèle contraint avec pentes communes et intercepts spécifiques.

La statistique est :

$$F_2 = \frac{(SCR_{1,c'} - SCR_1)/[(n-1)K]}{SCR_1/[nT - n(K+1)]}. \quad (7)$$

On rejette H_0^2 si F_2 est trop grand.

4.4 Étape 3 : intercepts communs ou effets fixes ? (test F_3)

Supposons maintenant que les pentes communes ne sont pas rejetées (H_0^2 vraie). On compare alors :

- **Modèle non contraint (Mnc)** : $Y_{it} = \alpha_i + \beta X_{it} + \varepsilon_{it}$;
- **Modèle constraint (Mc)** : $Y_{it} = \alpha + \beta X_{it} + \varepsilon_{it}$.

Hypothèses :

$$H_0^3 : \alpha_i = \alpha \quad \forall i \quad (\text{pas besoin d'effets fixes}),$$

$$H_1^3 : \exists (i, j) \text{ tels que } \alpha_i \neq \alpha_j.$$

On note :

- SCR_1 : SCR du modèle non contraint (effets fixes individuels) ;
- $SCR_{1,c''}$: SCR du modèle contraint (pooled avec pente commune).

La statistique est :

$$F_3 = \frac{(SCR_{1,c''} - SCR_1)/(n-1)}{SCR_1/[n(T-1) - K]}. \quad (8)$$

4.5 Illustration du processus

Si H_0^3 est rejetée, on conclut que les effets fixes individuels sont nécessaires : le modèle retenu est alors, en général,

$$Y_{it} = \alpha_i + \beta X_{it} + \varepsilon_{it}.$$

5 Application : climat et PIB agricole

On applique maintenant ces idées à un exemple stylisé inspiré de ton projet.

5.1 Spécification économétrique

On considère le modèle suivant :

$$\log(\text{PIB agri}_{it}) = \alpha_i + \gamma_t + \beta_1 \text{degdays}_{it} + \beta_2 \text{rain}_{it} + \beta_3 \text{hotdays}_{it} + \varepsilon_{it}, \quad (9)$$

où :

- α_i : niveau moyen de productivité agricole propre au pays i ;
- γ_t : choc commun à tous les pays en année t (prix mondiaux, tendance technologique, etc.) ;
- β_1 : effet marginal de la chaleur utile (degrés-jours) sur le PIB agricole ;
- β_2 : effet des précipitations de saison de croissance ;
- β_3 : effet du nombre de jours très chauds (attendu négatif).

On peut procéder comme suit :




FIGURE 2 – Illustration du processus.

1. Estimer un modèle pooled (sans α_i ni γ_t) et un modèle à pentes et intercepts spécifiques pour une seule variable (par exemple degdays_{it}) afin de calculer les tests F_1, F_2, F_3 à la Hsiao.
2. En pratique, sur des données climatiques et agricoles, on s'attend à ce que :
 - le pooled soit rejeté (F_1 significatif),
 - les pentes communes ne soient pas forcément rejetées (les pays réagissent de façon similaire aux variations climatiques),
 - les intercepts communs soient rejettés (F_3 significatif), ce qui justifie l'utilisation d'un **modèle à effets fixes individuels**.
3. On retient alors le modèle (9) estimé par **effets fixes pays + effets fixes temporels**.

5.2 Interprétation des coefficients dans ce contexte

Dans le modèle (9) estimé en FE :

- β_1 mesure l'effet d'une augmentation de la chaleur utile (par exemple +100 degrés-jours) sur le PIB agricole, à *pays donné* et *année donnée*. Si $\beta_1 > 0$, une hausse modérée des degrés-jours est bénéfique à la production.
- β_2 traduit l'effet d'une augmentation des précipitations en saison de croissance. Trop peu de pluie est défavorable, mais trop de pluie peut aussi être nuisible : on peut donc envisager un terme quadratique si besoin.
- β_3 capte l'effet des journées *trop chaudes*. On s'attend souvent à un coefficient négatif : plus de jours dépassant un seuil critique réduit les rendements.

Les effets fixes α_i ne sont pas interprétés individuellement, mais ils permettent de neutraliser des facteurs structurels inobservés (sols, institutions, politiques agricoles de long terme, etc.).

5.3 Implémentation pratique en R (avec `plm`)

Voici un exemple de code R (à adapter à ta vraie base de données) pour estimer le modèle FE et réaliser un test de Hausman entre FE et RE.

```

library(plm)

# On suppose que 'panel' contient :
# country, year, degdays, rain, hotdays, agri_gdp

panel$log_agri_gdp <- log(panel$agri_gdp)

# Déclaration du panel
pdata <- pdata.frame(panel, index = c("country", "year"))

# Modèle pooled
pool_mod <- plm(
  log_agri_gdp ~ degdays + rain + hotdays,
  data = pdata,
  model = "pooling"
)

# Modèle effets fixes pays + années
fe_tw <- plm(
  log_agri_gdp ~ degdays + rain + hotdays,
  data = pdata,
  model = "within",
  effect = "twoways"
)

# Modèle effets aléatoires
re_mod <- plm(
  log_agri_gdp ~ degdays + rain + hotdays,
  data = pdata,
  model = "random",
  effect = "individual"
)

summary(fe_tw)

# Test de Hausman : FE vs RE
phptest(fe_tw, re_mod)

```

Le test de Hausman fournit une autre manière de choisir entre FE et RE : si la p-value est faible, on rejette RE au profit de FE, ce qui est cohérent avec l'idée que les effets pays sont corrélés aux variables climatiques.

Conclusion

Ce cours a introduit les concepts de base des modèles statiques en données de panel : pooling, effets fixes, effets aléatoires, ainsi que les tests de spécification de Hsiao (2003). L'exemple climat-PIB agricole illustre comment ces outils peuvent être utilisés pour analyser l'impact des degrés-jours, des précipitations et des journées très chaudes sur l'activité agricole de plusieurs pays au cours du temps.

Dans un travail appliqué, il est important de combiner :

- une réflexion économique (quelle forme fonctionnelle est plausible?) ;
- une inspection des données (graphes, statistiques descriptives) ;
- et des tests économétriques (Hsiao, Hausman, tests de spécification, tests de résidus).